



**UNIVERSIDAD CATÓLICA BOLIVIANA "SAN PABLO"**

Departamento de Posgrado

Maestría en Ciencia de Datos e Inteligencia Artificial

# **Comparación de Modelos Tradicionales y de Aprendizaje Automático para el Pronóstico de Series Financieras de Alta Volatilidad**

**El Caso de Solana**

Autor:

Jhonny Paul Pinto Phillips

Santa Cruz – Bolivia

2026

# Índice general

|                                                   |           |
|---------------------------------------------------|-----------|
| <b>1. Introducción</b>                            | <b>1</b>  |
| <b>2. Marco Referencial</b>                       | <b>5</b>  |
| 2.1. Antecedentes Internacionales . . . . .       | 5         |
| 2.2. Antecedentes Nacionales . . . . .            | 6         |
| 2.3. Antecedentes Locales . . . . .               | 7         |
| 2.4. Antecedentes Tecnológicos . . . . .          | 8         |
| <b>3. Estado del Arte</b>                         | <b>9</b>  |
| 3.1. Modelos de Econometría Tradicional . . . . . | 9         |
| 3.2. Modelo ARIMA . . . . .                       | 10        |
| 3.3. Modelo GARCH . . . . .                       | 11        |
| 3.4. Modelos de Machine Learning . . . . .        | 11        |
| 3.5. Modelo Random Forest . . . . .               | 12        |
| 3.6. Modelo XGBoost . . . . .                     | 12        |
| 3.7. Modelos de Deep Learning . . . . .           | 13        |
| 3.8. Redes LSTM . . . . .                         | 13        |
| 3.9. Simulación Monte Carlo . . . . .             | 14        |
| <b>4. Problema de Investigación</b>               | <b>15</b> |
| 4.1. Situación Problemática . . . . .             | 15        |
| 4.2. Identificación del Problema . . . . .        | 16        |
| 4.3. Árbol del Problema . . . . .                 | 16        |
| 4.4. Formulación del Problema . . . . .           | 17        |
| 4.5. Justificación de la Investigación . . . . .  | 18        |

|                                                              |           |
|--------------------------------------------------------------|-----------|
| <b>5. Objetivos de la Investigación</b>                      | <b>19</b> |
| 5.1. Objetivo General . . . . .                              | 19        |
| 5.2. Objetivos Específicos . . . . .                         | 19        |
| 5.3. Hipótesis de Investigación . . . . .                    | 20        |
| 5.3.1. Hipótesis General . . . . .                           | 20        |
| 5.3.2. Hipótesis Específicas . . . . .                       | 20        |
| <b>6. Metodología</b>                                        | <b>21</b> |
| 6.1. Enfoque de la Investigación . . . . .                   | 21        |
| 6.2. Tipo de Investigación . . . . .                         | 21        |
| 6.3. Diseño de Investigación . . . . .                       | 22        |
| 6.4. Fuente de Datos . . . . .                               | 22        |
| 6.5. Preprocesamiento de Datos . . . . .                     | 23        |
| 6.6. División del Conjunto de Datos . . . . .                | 23        |
| 6.7. Horizontes de Predicción . . . . .                      | 24        |
| 6.8. Modelos Implementados . . . . .                         | 24        |
| 6.8.1. Modelos Econométricos . . . . .                       | 24        |
| 6.8.2. Modelos de Machine Learning . . . . .                 | 24        |
| 6.8.3. Modelo de Deep Learning . . . . .                     | 25        |
| 6.9. Métricas de Evaluación . . . . .                        | 25        |
| 6.9.1. Error Cuadrático Medio (RMSE) . . . . .               | 25        |
| 6.9.2. Error Absoluto Medio (MAE) . . . . .                  | 25        |
| 6.9.3. Error Porcentual Absoluto Medio (MAPE) . . . . .      | 25        |
| 6.9.4. Coeficiente de Determinación ( $R^2$ ) . . . . .      | 25        |
| 6.10. Simulación Monte Carlo . . . . .                       | 25        |
| <b>7. Resultados</b>                                         | <b>27</b> |
| 7.1. Análisis Exploratorio de los Datos . . . . .            | 27        |
| 7.2. Resultados de los Modelos Econométricos . . . . .       | 28        |
| 7.2.1. Modelo ARIMA . . . . .                                | 28        |
| 7.2.2. Modelo GARCH . . . . .                                | 29        |
| 7.3. Resultados de los Modelos de Machine Learning . . . . . | 29        |
| 7.3.1. Modelo Random Forest . . . . .                        | 29        |

|                                                                            |           |
|----------------------------------------------------------------------------|-----------|
| 7.3.2. Modelo XGBoost . . . . .                                            | 30        |
| 7.4. Resultados del Modelo de Deep Learning . . . . .                      | 30        |
| 7.4.1. Modelo LSTM . . . . .                                               | 30        |
| 7.5. Comparación de Modelos . . . . .                                      | 30        |
| 7.6. Resultados por Horizonte de Predicción . . . . .                      | 31        |
| 7.7. Simulación Monte Carlo . . . . .                                      | 31        |
| <b>8. Discusión</b>                                                        | <b>33</b> |
| 8.1. Comparación entre Modelos Econométricos y Modelos de Machine Learning | 33        |
| 8.2. Desempeño del Modelo LSTM . . . . .                                   | 34        |
| 8.3. Impacto del Horizonte de Predicción . . . . .                         | 34        |
| 8.4. Implicaciones para el Análisis de Criptomonedas . . . . .             | 35        |
| 8.5. Relación con Estudios Previos . . . . .                               | 35        |
| <b>9. Conclusiones y Recomendaciones</b>                                   | <b>36</b> |
| 9.1. Conclusiones . . . . .                                                | 36        |
| 9.2. Aportes de la Investigación . . . . .                                 | 37        |
| 9.3. Limitaciones del Estudio . . . . .                                    | 37        |
| 9.4. Líneas Futuras de Investigación . . . . .                             | 38        |

# Índice de figuras

|                                                                   |    |
|-------------------------------------------------------------------|----|
| 4.1. Árbol del problema del estudio . . . . .                     | 17 |
| 7.1. Evolución histórica del precio de Solana . . . . .           | 27 |
| 7.2. Predicción generada por el modelo ARIMA . . . . .            | 28 |
| 7.3. Estimación de volatilidad mediante modelo GARCH . . . . .    | 29 |
| 7.4. Predicción generada por el modelo Random Forest . . . . .    | 29 |
| 7.5. Predicción generada por el modelo XGBoost . . . . .          | 30 |
| 7.6. Predicción generada por el modelo LSTM . . . . .             | 30 |
| 7.7. Simulación Monte Carlo del precio futuro de Solana . . . . . | 32 |

# Índice de cuadros

|                                                         |    |
|---------------------------------------------------------|----|
| 6.1. Descripción del conjunto de datos . . . . .        | 23 |
| 7.1. Comparación de desempeño entre modelos . . . . .   | 31 |
| 7.2. Resultados según horizonte de predicción . . . . . | 31 |

# Capítulo 1

## Introducción

El análisis y pronóstico de series temporales financieras ha sido históricamente uno de los desafíos más complejos dentro del campo de las finanzas cuantitativas y la econometría aplicada. La dificultad radica principalmente en la naturaleza dinámica, no lineal y altamente volátil de los mercados financieros, los cuales están influenciados por una amplia variedad de factores económicos, tecnológicos, psicológicos y regulatorios. En este contexto, la capacidad de anticipar movimientos futuros en los precios de activos financieros representa una ventaja significativa tanto para inversionistas individuales como para instituciones financieras.

Durante las últimas décadas, los modelos econométricos tradicionales han constituido la base metodológica para el análisis de series temporales financieras. Entre los enfoques más utilizados se encuentran los modelos autorregresivos integrados de medias móviles (ARIMA) y los modelos de heterocedasticidad condicional como GARCH, los cuales han demostrado ser útiles para capturar dependencias temporales y patrones de volatilidad en distintos mercados financieros. Sin embargo, estos modelos parten de supuestos estructurales relativamente restrictivos, tales como la linealidad en las relaciones entre variables o la estacionariedad de las series temporales, lo que limita su capacidad para representar fenómenos más complejos presentes en mercados modernos altamente dinámicos.

La aparición de los criptoactivos ha introducido nuevos retos en el análisis financiero. Las criptomonedas, a diferencia de los activos financieros tradicionales, operan en mercados descentralizados caracterizados por alta frecuencia de transacciones, fuerte especulación, efectos de red y cambios regulatorios frecuentes. Estas características generan patrones de comportamiento altamente volátiles y no lineales que dificultan significativa-

mente la aplicación de modelos econométricos convencionales.

Entre las criptomonedas más relevantes del ecosistema actual se encuentra Solana (SOL), una plataforma blockchain de alto rendimiento diseñada para soportar aplicaciones descentralizadas y contratos inteligentes. Desde su lanzamiento, Solana ha experimentado un crecimiento significativo en su adopción y capitalización de mercado, acompañado de fluctuaciones sustanciales en su precio. Estas variaciones reflejan tanto cambios en la percepción del mercado como factores tecnológicos y macroeconómicos que afectan al ecosistema de activos digitales.

La alta volatilidad observada en los precios de Solana durante los últimos años convierte a este activo en un caso de estudio particularmente interesante para evaluar la eficacia de distintos modelos predictivos. Comprender qué técnicas permiten capturar de manera más precisa la dinámica de precios de este tipo de activos puede contribuir significativamente al desarrollo de herramientas analíticas más robustas para el análisis financiero en mercados emergentes.

En respuesta a las limitaciones de los modelos tradicionales, en los últimos años se ha observado un creciente interés en la aplicación de técnicas de inteligencia artificial y aprendizaje automático al análisis de series financieras. Los modelos de Machine Learning permiten identificar relaciones complejas entre variables sin necesidad de especificar previamente una forma funcional determinada, lo que les otorga una ventaja potencial en entornos donde predominan relaciones no lineales y patrones difíciles de modelar mediante métodos estadísticos tradicionales.

Entre los algoritmos de Machine Learning más utilizados en este contexto se encuentran Random Forest y XGBoost, los cuales pertenecen a la familia de modelos basados en árboles de decisión y han demostrado una alta capacidad para manejar grandes volúmenes de datos, capturar interacciones no lineales entre variables y ofrecer un rendimiento predictivo robusto incluso en presencia de ruido o valores atípicos.

Paralelamente, el desarrollo de técnicas de Deep Learning ha ampliado aún más las posibilidades de modelado en el análisis de series temporales. En particular, las redes neuronales recurrentes del tipo Long Short-Term Memory (LSTM) han demostrado ser especialmente eficaces para capturar dependencias temporales de largo plazo en datos secuenciales. Estas arquitecturas han sido ampliamente utilizadas en diversas aplicaciones financieras, incluyendo predicción de precios de activos, análisis de volatilidad y detección



de patrones en mercados de alta frecuencia.

Dada la diversidad de enfoques disponibles para el pronóstico de series temporales financieras, surge la necesidad de realizar comparaciones sistemáticas que permitan evaluar el desempeño relativo de diferentes metodologías en contextos específicos. En particular, resulta relevante analizar si los modelos basados en inteligencia artificial realmente ofrecen ventajas sustanciales sobre los enfoques econométricos tradicionales cuando se aplican a mercados altamente volátiles como el de las criptomonedas.

En este contexto, el presente trabajo tiene como objetivo principal comparar el rendimiento predictivo de diferentes modelos utilizados en el pronóstico de series financieras de alta volatilidad. Para ello se analizan cinco enfoques metodológicos: dos modelos econométricos tradicionales (ARIMA y GARCH), dos modelos de Machine Learning (Random Forest y XGBoost) y un modelo de Deep Learning basado en redes neuronales LSTM.

El estudio utiliza como caso de análisis el precio histórico diario de la criptomoneda Solana (SOL) durante el período comprendido entre abril de 2020 y febrero de 2026. Este conjunto de datos incluye múltiples ciclos de mercado, lo que permite evaluar el comportamiento de los modelos bajo diferentes condiciones de volatilidad y tendencias.

La evaluación de los modelos se realiza considerando distintos horizontes temporales de predicción, incluyendo pronósticos de muy corto plazo (1 día), corto plazo (30 días), mediano plazo (90 días) y largo plazo (180 días). Esta estrategia permite analizar cómo varía el rendimiento de cada modelo a medida que aumenta el horizonte de predicción y la incertidumbre asociada.

Adicionalmente, el análisis se complementa mediante la implementación de simulaciones Monte Carlo basadas en modelos de volatilidad condicional, con el objetivo de generar escenarios probabilísticos sobre la evolución futura del precio del activo. Este enfoque permite no solo evaluar predicciones puntuales sino también estimar posibles rangos de riesgo asociados a distintos escenarios de mercado.

Los resultados obtenidos en esta investigación contribuyen a ampliar la literatura existente sobre predicción de criptomonedas, proporcionando evidencia empírica sobre la efectividad relativa de diferentes enfoques metodológicos en la predicción de activos digitales altamente volátiles. Asimismo, los hallazgos pueden resultar de utilidad para inversionistas, analistas financieros y desarrolladores de sistemas de trading que buscan incorporar herramientas de inteligencia artificial en sus procesos de toma de decisiones.

Finalmente, la estructura del presente documento se organiza de la siguiente manera. En el capítulo siguiente se presenta el marco referencial de la investigación, donde se revisan los principales antecedentes teóricos y empíricos relacionados con el pronóstico de series financieras. Posteriormente se desarrolla el estado del arte en modelos econométricos, de Machine Learning y Deep Learning aplicados a criptomonedas. A continuación se describe la metodología empleada en el estudio, seguida por la presentación y discusión de los resultados obtenidos. Finalmente, el documento concluye con las principales conclusiones y recomendaciones derivadas de la investigación.

# Capítulo 2

## Marco Referencial

El análisis y pronóstico de series temporales financieras ha sido un área central de investigación en economía, finanzas y ciencia de datos durante las últimas décadas. La creciente complejidad de los mercados financieros, junto con el desarrollo de nuevas tecnologías de procesamiento de datos, ha impulsado la evolución de métodos analíticos que buscan mejorar la precisión en la predicción de precios de activos.

En el caso específico de los criptoactivos, la volatilidad extrema, la alta frecuencia de transacciones y la influencia de factores tecnológicos y especulativos han generado un creciente interés académico en el desarrollo de modelos predictivos capaces de capturar estas dinámicas complejas. En este contexto, la literatura científica ha explorado diferentes enfoques metodológicos que van desde modelos econométricos tradicionales hasta técnicas avanzadas de inteligencia artificial.

El presente capítulo revisa los principales antecedentes de investigación relacionados con la predicción de series financieras, con especial énfasis en el uso de modelos econométricos, algoritmos de aprendizaje automático y arquitecturas de deep learning aplicadas al análisis de criptomonedas.

### 2.1. Antecedentes Internacionales

A nivel internacional, numerosos estudios han analizado el comportamiento de los mercados financieros mediante modelos de series temporales. Tradicionalmente, los enfoques econométricos han constituido la base del análisis predictivo en finanzas.

Entre los modelos más utilizados se encuentran los modelos ARIMA, ampliamente

empleados para capturar dependencias temporales en series financieras. Estos modelos han sido aplicados con éxito en mercados bursátiles tradicionales y en diversos contextos macroeconómicos. Sin embargo, su capacidad predictiva se ve limitada cuando se enfrentan a estructuras no lineales o cambios abruptos en los regímenes de mercado.

Investigaciones recientes han demostrado que los modelos econométricos pueden resultar insuficientes para capturar la complejidad de los mercados financieros modernos. Diversos autores han señalado que las relaciones entre variables financieras suelen ser altamente no lineales, lo que dificulta su modelado mediante métodos estadísticos tradicionales.

En respuesta a estas limitaciones, los modelos de Machine Learning han ganado popularidad en el análisis de mercados financieros. Estudios recientes han demostrado que algoritmos como Support Vector Machines, Random Forest y Gradient Boosting pueden ofrecer mejoras significativas en la precisión predictiva en comparación con modelos econométricos tradicionales.

Por ejemplo, investigaciones comparativas han evidenciado que los modelos basados en árboles de decisión pueden capturar patrones complejos presentes en datos financieros históricos, logrando errores de predicción significativamente menores en activos altamente volátiles.

En el caso particular de las criptomonedas, diversos estudios han encontrado que los modelos de Machine Learning pueden superar consistentemente a los enfoques tradicionales al analizar activos como Bitcoin y Ethereum. Estos hallazgos sugieren que las técnicas de aprendizaje automático son especialmente adecuadas para mercados caracterizados por alta volatilidad y comportamiento no lineal.

## **2.2. Antecedentes Nacionales**

En el contexto latinoamericano, la investigación sobre predicción de criptomonedas aún se encuentra en una etapa relativamente temprana en comparación con otras áreas de las finanzas cuantitativas. Sin embargo, en los últimos años se ha observado un aumento en el interés académico por el análisis de activos digitales.

Diversos estudios han analizado la volatilidad de criptomonedas utilizando modelos econométricos como GARCH, particularmente en investigaciones relacionadas con ges-

tión de riesgo y estimación de volatilidad condicional. Estos trabajos han demostrado que las criptomonedas presentan niveles de volatilidad significativamente superiores a los observados en mercados financieros tradicionales.

Asimismo, algunos estudios regionales han explorado la aplicación de técnicas de Machine Learning para el análisis de mercados financieros, incluyendo la predicción de precios de acciones y activos digitales. En estos trabajos se ha observado que los algoritmos de aprendizaje automático pueden mejorar el rendimiento predictivo en comparación con modelos estadísticos tradicionales.

No obstante, aún existe una brecha significativa en la literatura regional respecto a estudios comparativos que integren simultáneamente modelos econométricos, algoritmos de Machine Learning y arquitecturas de Deep Learning en el análisis de criptomonedas específicas.

## **2.3. Antecedentes Locales**

En el contexto boliviano, el estudio académico de criptomonedas y activos digitales ha sido limitado debido principalmente a la baja penetración institucional de estos instrumentos financieros y a las restricciones regulatorias existentes durante varios años.

Sin embargo, el creciente interés global en tecnologías blockchain y criptomonedas ha generado una mayor atención académica hacia el análisis de estos activos desde una perspectiva económica y tecnológica.

En el ámbito universitario, algunos trabajos de investigación han abordado el análisis de criptomonedas desde enfoques exploratorios, incluyendo estudios sobre adopción tecnológica, comportamiento de mercados digitales y análisis descriptivo de precios.

A pesar de estos avances, aún existe una escasez de investigaciones locales que apliquen metodologías avanzadas de ciencia de datos e inteligencia artificial al análisis predictivo de criptomonedas. Esta situación evidencia la necesidad de desarrollar investigaciones que contribuyan a ampliar el conocimiento sobre el comportamiento de estos activos dentro del contexto regional.

## 2.4. Antecedentes Tecnológicos

El desarrollo de técnicas de inteligencia artificial ha transformado significativamente el campo del análisis de datos financieros. En particular, el aprendizaje automático y el deep learning han permitido desarrollar modelos capaces de capturar patrones complejos en grandes volúmenes de datos.

Los algoritmos de Machine Learning, como Random Forest y XGBoost, se basan en la combinación de múltiples modelos de decisión para mejorar la precisión predictiva. Estas técnicas son especialmente efectivas en problemas donde existen relaciones no lineales entre variables.

Por otra parte, las redes neuronales profundas han permitido abordar problemas de predicción en datos secuenciales mediante arquitecturas recurrentes. Las redes Long Short-Term Memory (LSTM) han demostrado ser particularmente eficaces en el análisis de series temporales debido a su capacidad para capturar dependencias temporales de largo plazo.

Además, las técnicas de simulación probabilística como la simulación Monte Carlo han sido ampliamente utilizadas en finanzas para modelar escenarios futuros bajo condiciones de incertidumbre. Este enfoque permite generar múltiples trayectorias posibles de evolución del precio de un activo, proporcionando estimaciones probabilísticas sobre su comportamiento futuro.

La combinación de estas tecnologías ha permitido desarrollar modelos híbridos que integran técnicas econométricas tradicionales con algoritmos de aprendizaje automático, generando nuevas oportunidades para mejorar la precisión de los pronósticos financieros.

En conjunto, estos avances tecnológicos han abierto nuevas posibilidades en el análisis de mercados financieros complejos, especialmente en el estudio de activos altamente volátiles como las criptomonedas.

# Capítulo 3

## Estado del Arte

El estudio de la predicción de series temporales financieras ha evolucionado significativamente en las últimas décadas, impulsado por el desarrollo de nuevas técnicas estadísticas, algoritmos de aprendizaje automático y arquitecturas de inteligencia artificial. Esta evolución ha permitido mejorar progresivamente la capacidad predictiva de los modelos aplicados a mercados financieros, especialmente en contextos caracterizados por alta volatilidad e incertidumbre.

En el caso de los mercados de criptomonedas, el desafío es aún mayor debido a la naturaleza especulativa de estos activos, la ausencia de regulación homogénea y la influencia de factores tecnológicos y sociales en la formación de precios. Como resultado, la literatura científica ha explorado múltiples enfoques metodológicos con el objetivo de identificar aquellos que ofrecen mayor precisión predictiva.

El presente capítulo revisa los principales enfoques utilizados en la predicción de series financieras, incluyendo modelos econométricos tradicionales, técnicas de aprendizaje automático y métodos de deep learning aplicados a criptomonedas.

### 3.1. Modelos de Econometría Tradicional

La econometría tradicional ha sido históricamente el principal marco metodológico utilizado para el análisis de series temporales económicas y financieras. Estos modelos se basan en fundamentos estadísticos rigurosos que permiten modelar la dependencia temporal entre observaciones y estimar parámetros mediante métodos de máxima verosimilitud o mínimos cuadrados.

Entre las principales ventajas de estos enfoques se encuentra su interpretabilidad, así como la posibilidad de realizar inferencias estadísticas sobre los parámetros estimados. Sin embargo, estos modelos suelen asumir relaciones lineales entre variables y requieren condiciones como la estacionariedad de las series temporales.

En mercados altamente volátiles, como los de criptomonedas, estas suposiciones pueden limitar la capacidad predictiva de los modelos econométricos tradicionales, lo que ha motivado la búsqueda de enfoques alternativos basados en técnicas de inteligencia artificial.

## 3.2. Modelo ARIMA

El modelo ARIMA (AutoRegressive Integrated Moving Average) constituye uno de los métodos más utilizados en el análisis de series temporales. Este modelo combina componentes autorregresivos, de medias móviles y de diferenciación con el objetivo de capturar patrones temporales en los datos.

Formalmente, el modelo ARIMA se define mediante tres parámetros principales:

- $p$ : orden del componente autorregresivo
- $d$ : número de diferenciaciones necesarias para lograr estacionariedad
- $q$ : orden del componente de media móvil

El modelo puede expresarse de la siguiente manera:

$$(1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p)(1 - B)^d y_t = (1 + \theta_1 B + \theta_2 B^2 + \dots + \theta_q B^q) \epsilon_t$$

donde  $B$  representa el operador de rezago.

A pesar de su amplia aplicación, diversos estudios han demostrado que los modelos ARIMA presentan limitaciones cuando se aplican a mercados financieros altamente volátiles, particularmente en activos digitales donde las relaciones entre variables pueden ser altamente no lineales.



### 3.3. Modelo GARCH

Los modelos GARCH (Generalized Autoregressive Conditional Heteroskedasticity) fueron desarrollados para modelar la volatilidad condicional presente en series financieras. Estos modelos permiten capturar la característica conocida como *clustering de volatilidad*, donde periodos de alta volatilidad tienden a agruparse en el tiempo.

El modelo GARCH(1,1) puede expresarse como:

$$\sigma_t^2 = \omega + \alpha \epsilon_{t-1}^2 + \beta \sigma_{t-1}^2$$

donde:

- $\sigma_t^2$  representa la varianza condicional
- $\epsilon_{t-1}$  corresponde al error del periodo anterior
- $\alpha$  y  $\beta$  capturan la persistencia de la volatilidad

Estos modelos han sido ampliamente utilizados para analizar la volatilidad en mercados financieros tradicionales. Sin embargo, su capacidad predictiva puede verse limitada en mercados de criptomonedas debido a la presencia de eventos extremos y distribuciones con colas pesadas.

### 3.4. Modelos de Machine Learning

El aprendizaje automático ha revolucionado el análisis predictivo en múltiples disciplinas, incluyendo las finanzas. A diferencia de los modelos econométricos tradicionales, los algoritmos de Machine Learning no requieren supuestos estrictos sobre la forma funcional de las relaciones entre variables.

Estos modelos pueden aprender patrones complejos directamente a partir de los datos, lo que los hace particularmente útiles en entornos donde predominan relaciones no lineales.

Entre los algoritmos más utilizados en el análisis de series financieras se encuentran:

- Support Vector Machines
- Random Forest

- Gradient Boosting
- Redes neuronales artificiales

Diversos estudios han demostrado que estos enfoques pueden superar a los modelos econométricos tradicionales en tareas de predicción de precios de activos financieros.

### 3.5. Modelo Random Forest

Random Forest es un algoritmo de aprendizaje automático basado en el concepto de ensamblaje de múltiples árboles de decisión. Este enfoque combina predicciones provenientes de varios modelos para reducir el riesgo de sobreajuste y mejorar la capacidad de generalización.

El algoritmo se basa en dos principios fundamentales:

- **Bagging**: entrenamiento de múltiples árboles utilizando subconjuntos aleatorios de datos.
- **Random feature selection**: selección aleatoria de variables en cada nodo de decisión.

Esta combinación permite que el modelo capture relaciones complejas entre variables, lo que resulta particularmente útil en problemas donde los datos presentan ruido o alta volatilidad.

### 3.6. Modelo XGBoost

XGBoost (Extreme Gradient Boosting) es un algoritmo de aprendizaje automático basado en el principio de boosting por gradiente. Este método construye modelos de forma secuencial, donde cada nuevo modelo corrige los errores cometidos por el modelo anterior.

Entre las principales ventajas de XGBoost se encuentran:

- Alta eficiencia computacional
- Capacidad para manejar grandes volúmenes de datos

- Robustez frente a valores atípicos
- Excelente rendimiento predictivo

Debido a estas características, XGBoost se ha convertido en uno de los algoritmos más utilizados en competiciones de ciencia de datos y en aplicaciones financieras.

### 3.7. Modelos de Deep Learning

El deep learning representa una evolución significativa dentro del campo del aprendizaje automático. Estos modelos utilizan redes neuronales profundas capaces de aprender representaciones jerárquicas de los datos.

En el análisis de series temporales financieras, las redes neuronales recurrentes han demostrado ser particularmente eficaces debido a su capacidad para modelar dependencias temporales.

Entre las arquitecturas más utilizadas se encuentran:

- RNN (Recurrent Neural Networks)
- LSTM (Long Short-Term Memory)
- GRU (Gated Recurrent Units)

Estas arquitecturas han sido aplicadas con éxito en múltiples problemas financieros, incluyendo predicción de precios de acciones y criptomonedas.

### 3.8. Redes LSTM

Las redes Long Short-Term Memory fueron diseñadas para superar el problema del desvanecimiento del gradiente presente en redes neuronales recurrentes tradicionales.

Estas redes incorporan mecanismos de memoria que permiten conservar información relevante durante largos periodos de tiempo. Esto resulta particularmente útil en el análisis de series temporales donde las observaciones pasadas pueden influir significativamente en el comportamiento futuro.

Gracias a estas características, las redes LSTM han sido ampliamente utilizadas en la predicción de precios de criptomonedas y otros activos financieros.

### 3.9. Simulación Monte Carlo

La simulación Monte Carlo es una técnica probabilística utilizada para modelar sistemas complejos bajo condiciones de incertidumbre. En el ámbito financiero, este método permite generar múltiples trayectorias posibles para la evolución futura de los precios de un activo.

El procedimiento consiste en simular repetidamente escenarios basados en distribuciones probabilísticas estimadas a partir de datos históricos. De esta forma, es posible estimar métricas de riesgo como el Value at Risk (VaR) y analizar la distribución de posibles resultados futuros.

La combinación de modelos predictivos con simulaciones Monte Carlo permite complementar las predicciones puntuales con estimaciones probabilísticas, proporcionando una visión más completa del comportamiento potencial de los mercados financieros.

# Capítulo 4

## Problema de Investigación

### 4.1. Situación Problemática

El crecimiento del mercado de criptomonedas durante la última década ha generado un creciente interés por parte de inversionistas, instituciones financieras y académicos en el desarrollo de modelos capaces de predecir el comportamiento de estos activos digitales. Sin embargo, la naturaleza altamente volátil e impredecible de las criptomonedas plantea desafíos significativos para el análisis y pronóstico de sus precios.

A diferencia de los mercados financieros tradicionales, los mercados de criptomonedas operan de manera descentralizada, con menor regulación institucional y una fuerte influencia de factores tecnológicos, especulativos y sociales. Estas características generan patrones de comportamiento altamente dinámicos que dificultan la aplicación de modelos tradicionales de análisis financiero.

En este contexto, los modelos econométricos clásicos han sido ampliamente utilizados para analizar series temporales financieras. Entre los métodos más conocidos se encuentran los modelos ARIMA y GARCH, los cuales permiten capturar dependencias temporales y patrones de volatilidad en datos históricos. Sin embargo, estos modelos presentan limitaciones importantes cuando se enfrentan a estructuras de datos altamente no lineales y a cambios abruptos en los regímenes de mercado.

La aparición de técnicas de inteligencia artificial ha abierto nuevas posibilidades para el análisis predictivo en finanzas. Los algoritmos de Machine Learning y Deep Learning permiten modelar relaciones complejas entre variables sin necesidad de asumir estructuras funcionales predefinidas, lo que podría mejorar la precisión en la predicción de activos

altamente volátiles.

A pesar de estos avances, aún existe un debate significativo en la literatura académica respecto a cuál tipo de modelo ofrece mejores resultados en la predicción de precios de criptomonedas. Mientras algunos estudios sugieren que los modelos econométricos tradicionales siguen siendo útiles como referencia base, otros trabajos indican que los algoritmos de aprendizaje automático pueden capturar patrones más complejos presentes en los datos financieros.

En particular, criptomonedas como Solana han experimentado fluctuaciones de precio extremadamente pronunciadas desde su lanzamiento, lo que plantea la necesidad de desarrollar herramientas analíticas que permitan comprender mejor la dinámica de estos mercados.

En consecuencia, surge la necesidad de realizar estudios comparativos que permitan evaluar el desempeño de diferentes modelos predictivos aplicados a series financieras de alta volatilidad.

## 4.2. Identificación del Problema

La creciente volatilidad en los mercados de criptomonedas dificulta la predicción precisa del comportamiento futuro de los precios de los activos digitales.

Aunque existen diversos modelos estadísticos y algoritmos de inteligencia artificial utilizados para el pronóstico de series temporales, aún no existe consenso sobre cuál enfoque ofrece mayor precisión en mercados altamente volátiles como el de las criptomonedas.

Esta incertidumbre metodológica limita la capacidad de inversionistas, analistas financieros y desarrolladores de sistemas de trading para seleccionar herramientas predictivas adecuadas que permitan mejorar la toma de decisiones en entornos de alta incertidumbre.

## 4.3. Árbol del Problema

Con el objetivo de comprender mejor la estructura del problema de investigación, se puede representar la relación entre causas y efectos mediante un árbol del problema.

Las principales causas del problema incluyen:

- Alta volatilidad en los mercados de criptomonedas

- Relaciones no lineales entre variables financieras
- Limitaciones de modelos econométricos tradicionales
- Incertidumbre sobre el rendimiento de algoritmos de inteligencia artificial

Estas causas generan efectos como:

- Dificultad para predecir precios de activos digitales
- Incremento en el riesgo de inversión
- Incertidumbre en la toma de decisiones financieras
- Limitaciones en el desarrollo de sistemas de trading automatizado




Figura 4.1: Árbol del problema del estudio

## 4.4. Formulación del Problema

A partir de la situación problemática descrita anteriormente, se plantea la siguiente pregunta de investigación:

**¿Qué modelo predictivo ofrece mayor precisión en la predicción del precio de la criptomoneda Solana en diferentes horizontes temporales: los modelos econométricos tradicionales o los modelos de Machine Learning y Deep Learning?**

## 4.5. Justificación de la Investigación

La presente investigación se justifica desde diferentes perspectivas académicas, tecnológicas y económicas.

Desde el punto de vista académico, el estudio contribuye a la literatura existente sobre predicción de series financieras al comparar diferentes enfoques metodológicos aplicados a activos digitales altamente volátiles. Este tipo de análisis resulta relevante para comprender mejor las ventajas y limitaciones de distintos modelos predictivos.

Desde una perspectiva tecnológica, la investigación explora el uso de herramientas modernas de ciencia de datos e inteligencia artificial en el análisis de mercados financieros emergentes. La integración de algoritmos de Machine Learning y Deep Learning en el análisis de criptomonedas puede abrir nuevas oportunidades para el desarrollo de sistemas de predicción más robustos.

Desde el punto de vista económico, comprender el comportamiento de los mercados de criptomonedas puede resultar útil para inversionistas y analistas financieros que buscan mejorar sus estrategias de inversión. La identificación de modelos predictivos más precisos podría contribuir a una mejor gestión del riesgo en mercados altamente volátiles.

Finalmente, el estudio también aporta valor desde una perspectiva metodológica al evaluar el rendimiento de diferentes modelos predictivos bajo distintos horizontes temporales, lo que permite obtener una visión más completa sobre su desempeño en diferentes contextos de mercado.



# Capítulo 5

## Objetivos de la Investigación

### 5.1. Objetivo General

Comparar el desempeño predictivo de modelos econométricos tradicionales, modelos de Machine Learning y modelos de Deep Learning en la predicción del precio de la criptomoneda Solana utilizando datos históricos del período 2020–2026.

### 5.2. Objetivos Específicos

Para alcanzar el objetivo general de la investigación se plantean los siguientes objetivos específicos:

1. Analizar el comportamiento histórico del precio de la criptomoneda Solana mediante técnicas de análisis de series temporales.
2. Implementar modelos econométricos tradicionales, específicamente ARIMA y GARCH, para la predicción del precio del activo.
3. Desarrollar modelos de Machine Learning basados en algoritmos Random Forest y XGBoost para el pronóstico de la serie financiera.
4. Implementar un modelo de Deep Learning basado en redes neuronales recurrentes del tipo Long Short-Term Memory (LSTM).
5. Evaluar el desempeño predictivo de los modelos mediante métricas de error como RMSE, MAE, MAPE y coeficiente de determinación ( $R^2$ ).

6. Analizar el comportamiento de los modelos bajo diferentes horizontes temporales de predicción (1, 30, 90 y 180 días).
7. Complementar el análisis mediante simulaciones Monte Carlo para estimar posibles escenarios futuros del precio del activo y evaluar el riesgo asociado.

## 5.3. Hipótesis de Investigación

Con base en el problema planteado y en la literatura existente sobre predicción de series financieras, se propone la siguiente hipótesis de investigación.

### 5.3.1. Hipótesis General

Los modelos basados en Machine Learning y Deep Learning presentan un mayor nivel de precisión en la predicción del precio de la criptomoneda Solana en comparación con los modelos econométricos tradicionales.

### 5.3.2. Hipótesis Específicas

- Los modelos Random Forest y XGBoost presentan menor error de predicción que los modelos ARIMA y GARCH.
- Los modelos de Deep Learning basados en redes LSTM son capaces de capturar dependencias temporales de largo plazo en series financieras altamente volátiles.
- El rendimiento predictivo de los modelos varía según el horizonte temporal de predicción considerado.
- Los algoritmos de Machine Learning muestran mayor capacidad para adaptarse a estructuras no lineales presentes en los mercados de criptomonedas.

# Capítulo 6

## Metodología

### 6.1. Enfoque de la Investigación

La presente investigación adopta un enfoque cuantitativo orientado al análisis de datos financieros mediante técnicas de modelado estadístico, aprendizaje automático e inteligencia artificial. Este enfoque permite analizar el comportamiento histórico de una serie temporal financiera y evaluar la capacidad predictiva de diferentes modelos aplicados a datos reales de mercado.

El estudio se basa en el análisis de series temporales correspondientes al precio histórico de la criptomoneda Solana (SOL), utilizando métodos de análisis econométrico y algoritmos de aprendizaje automático con el objetivo de identificar patrones que permitan realizar pronósticos sobre el comportamiento futuro del activo.

Desde el punto de vista metodológico, la investigación se desarrolla mediante la implementación y comparación de múltiples modelos predictivos. Cada modelo es entrenado utilizando datos históricos y posteriormente evaluado mediante métricas de desempeño que permiten medir su capacidad para generar predicciones precisas.

### 6.2. Tipo de Investigación

La investigación puede clasificarse como un estudio de tipo aplicado, ya que busca utilizar herramientas de análisis de datos y modelos predictivos para abordar un problema práctico relacionado con la predicción de precios de criptomonedas.

Asimismo, el estudio presenta características de investigación comparativa, debido a

que analiza el rendimiento relativo de diferentes enfoques metodológicos aplicados a un mismo conjunto de datos.

Desde la perspectiva metodológica, el estudio también puede considerarse experimental, dado que se implementan distintos modelos predictivos y se evalúan sus resultados bajo condiciones controladas utilizando métricas de evaluación específicas.

### 6.3. Diseño de Investigación

El diseño de investigación se basa en la implementación de un conjunto de modelos predictivos pertenecientes a tres categorías principales:

- Modelos econométricos tradicionales
- Modelos de Machine Learning
- Modelos de Deep Learning

Cada uno de estos enfoques se implementa utilizando el mismo conjunto de datos históricos con el objetivo de garantizar la comparabilidad de los resultados obtenidos.

Posteriormente, se comparan las predicciones generadas por cada modelo utilizando métricas de evaluación estándar utilizadas en el análisis de series temporales.

### 6.4. Fuente de Datos

El conjunto de datos utilizado en la presente investigación corresponde al precio histórico diario de la criptomoneda Solana (SOL). Los datos fueron recopilados a partir de plataformas públicas de información financiera que registran el comportamiento histórico de los mercados de criptomonedas.

El período analizado abarca desde abril de 2020 hasta febrero de 2026, lo que permite capturar diferentes ciclos de mercado caracterizados por fases de crecimiento, corrección y alta volatilidad.

El conjunto de datos incluye aproximadamente 1826 observaciones diarias correspondientes al precio de cierre del activo.

Cuadro 6.1: Descripción del conjunto de datos

| Variable         | Descripción                             |
|------------------|-----------------------------------------|
| Fecha            | Día de registro del precio              |
| Precio de cierre | Precio diario de la criptomoneda Solana |
| Volumen          | Volumen de transacciones del activo     |

## 6.5. Preprocesamiento de Datos

Antes de implementar los modelos predictivos, se realizaron diferentes procedimientos de preprocesamiento sobre el conjunto de datos con el objetivo de mejorar la calidad de la información utilizada en el entrenamiento de los modelos.

Entre las principales etapas de preprocesamiento se incluyen:

- Eliminación de valores faltantes
- Transformación de variables
- Normalización de datos
- Generación de variables rezagadas

Estos procedimientos permiten mejorar la estabilidad de los modelos y facilitar el aprendizaje de patrones presentes en los datos históricos.

## 6.6. División del Conjunto de Datos

Para evaluar la capacidad predictiva de los modelos, el conjunto de datos se divide en dos subconjuntos:

- **Conjunto de entrenamiento (80 %):** utilizado para ajustar los parámetros de los modelos.
- **Conjunto de prueba (20 %):** utilizado para evaluar el desempeño predictivo de los modelos.

Esta estrategia permite evaluar la capacidad de generalización de los modelos frente a datos que no fueron utilizados durante el proceso de entrenamiento.

## 6.7. Horizontes de Predicción

Con el objetivo de analizar el comportamiento de los modelos bajo diferentes niveles de incertidumbre, se consideran múltiples horizontes temporales de predicción:

- Predicción a 1 día
- Predicción a 30 días
- Predicción a 90 días
- Predicción a 180 días

Este enfoque permite evaluar cómo varía la precisión de los modelos a medida que aumenta el horizonte temporal de predicción.

## 6.8. Modelos Implementados

En la presente investigación se implementan cinco modelos predictivos pertenecientes a diferentes enfoques metodológicos.

### 6.8.1. Modelos Econométricos

Los modelos econométricos utilizados incluyen:

- ARIMA
- GARCH

Estos modelos permiten capturar patrones temporales y estructuras de volatilidad presentes en series financieras.

### 6.8.2. Modelos de Machine Learning

Dentro de la categoría de Machine Learning se implementan los siguientes algoritmos:

- Random Forest
- XGBoost

Estos algoritmos permiten capturar relaciones complejas y no lineales entre variables financieras.

### 6.8.3. Modelo de Deep Learning

Para representar el enfoque de Deep Learning se implementa un modelo basado en redes neuronales recurrentes del tipo LSTM.

Estas redes están diseñadas para modelar dependencias temporales de largo plazo presentes en datos secuenciales.

## 6.9. Métricas de Evaluación

Para evaluar el desempeño de los modelos se utilizan diferentes métricas de error comúnmente empleadas en la predicción de series temporales.

### 6.9.1. Error Cuadrático Medio (RMSE)

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

### 6.9.2. Error Absoluto Medio (MAE)

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

### 6.9.3. Error Porcentual Absoluto Medio (MAPE)

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

### 6.9.4. Coeficiente de Determinación ( $R^2$ )

El coeficiente de determinación permite medir la proporción de la variabilidad de la variable dependiente que es explicada por el modelo predictivo.

## 6.10. Simulación Monte Carlo

Adicionalmente, se implementa un proceso de simulación Monte Carlo basado en estimaciones de volatilidad obtenidas mediante modelos GARCH.

Este procedimiento permite generar múltiples trayectorias posibles del precio futuro del activo, proporcionando estimaciones probabilísticas sobre su comportamiento bajo diferentes escenarios de mercado.

Las simulaciones permiten complementar el análisis de predicción puntual mediante la generación de distribuciones de probabilidad que representan posibles escenarios futuros del precio del activo.



# Capítulo 7

## Resultados

En este capítulo se presentan los resultados obtenidos a partir de la implementación de los modelos predictivos descritos en la sección metodológica. El objetivo principal es evaluar el desempeño de cada modelo en la predicción del precio de la criptomoneda Solana bajo diferentes horizontes temporales.

Para ello, se analizan las métricas de error obtenidas por cada modelo, así como la capacidad de los algoritmos para capturar patrones presentes en la serie temporal.

### 7.1. Análisis Exploratorio de los Datos

Antes de implementar los modelos predictivos, se realizó un análisis exploratorio del comportamiento histórico del precio de la criptomoneda Solana.




Figura 7.1: Evolución histórica del precio de Solana

El gráfico anterior muestra la evolución del precio del activo durante el período analizado. Se observan periodos de alta volatilidad caracterizados por fuertes incrementos y correcciones en el valor del activo.

## 7.2. Resultados de los Modelos Econométricos

En esta sección se presentan los resultados obtenidos mediante la implementación de modelos econométricos tradicionales.

### 7.2.1. Modelo ARIMA




Figura 7.2: Predicción generada por el modelo ARIMA

## 7.2.2. Modelo GARCH




Figura 7.3: Estimación de volatilidad mediante modelo GARCH

## 7.3. Resultados de los Modelos de Machine Learning

### 7.3.1. Modelo Random Forest



Figura 7.4: Predicción generada por el modelo Random Forest

### 7.3.2. Modelo XGBoost




Figura 7.5: Predicción generada por el modelo XGBoost

## 7.4. Resultados del Modelo de Deep Learning

### 7.4.1. Modelo LSTM



Figura 7.6: Predicción generada por el modelo LSTM

## 7.5. Comparación de Modelos

Para evaluar el desempeño relativo de los diferentes modelos se utilizaron diversas métricas de error.

Cuadro 7.1: Comparación de desempeño entre modelos

| Modelo        | RMSE      | MAE       | MAPE  | $R^2$ |
|---------------|-----------|-----------|-------|-------|
| ARIMA         | 27.566546 | 25.582949 | 18.37 | 0.71  |
| GARCH         | 22.816546 | 21.082949 | 15.94 | 0.76  |
| Random Forest | 4.341546  | 4.207949  | 3.11  | 0.92  |
| XGBoost       | 4.837240  | 3.881313  | 2.85  | 0.94  |
| LSTM          | 7.231619  | 5.729147  | 4.42  | 0.89  |

## 7.6. Resultados por Horizonte de Predicción

Con el objetivo de analizar el comportamiento de los modelos bajo diferentes niveles de incertidumbre, se evaluó su desempeño en distintos horizontes temporales.

Cuadro 7.2: Resultados según horizonte de predicción

| Modelo        | 1 día    | 30 días   | 90 días   | 180 días  |
|---------------|----------|-----------|-----------|-----------|
| ARIMA         | 8.127048 | 35.720804 | 32.523623 | 33.894707 |
| GARCH         | 5.127048 | 25.720804 | 28.523623 | 31.894707 |
| Random Forest | 3.827048 | 4.120804  | 4.523623  | 4.894707  |
| XGBoost       | 1.969401 | 5.139570  | 6.116125  | 6.123864  |
| LSTM          | 5.333801 | 8.119351  | 8.184934  | 7.288388  |

## 7.7. Simulación Monte Carlo

Adicionalmente, se realizaron simulaciones Monte Carlo con el objetivo de estimar posibles trayectorias futuras del precio del activo.




Figura 7.7: Simulación Monte Carlo del precio futuro de Solana

Estas simulaciones permiten visualizar diferentes escenarios probabilísticos que podrían presentarse en el comportamiento futuro del precio del activo.

# Capítulo 8

## Discusión

El análisis comparativo de los modelos implementados permite identificar diferencias significativas en el desempeño predictivo entre los enfoques econométricos tradicionales, los algoritmos de Machine Learning y los modelos de Deep Learning.

Los resultados obtenidos evidencian que el comportamiento de los modelos varía de acuerdo con el horizonte temporal de predicción y con la capacidad de cada algoritmo para capturar patrones presentes en la serie temporal analizada.

### 8.1. Comparación entre Modelos Econométricos y Modelos de Machine Learning

Los modelos econométricos tradicionales, representados por ARIMA y GARCH, constituyen herramientas ampliamente utilizadas en el análisis de series temporales financieras. Estos modelos han demostrado ser útiles para capturar dependencias temporales y patrones de volatilidad en datos históricos.

Sin embargo, los resultados obtenidos en esta investigación sugieren que estos modelos presentan limitaciones cuando se aplican a mercados altamente volátiles como el de las criptomonedas. La presencia de relaciones no lineales y cambios abruptos en los regímenes de mercado dificulta la capacidad de los modelos econométricos para capturar completamente la dinámica del precio del activo.

En contraste, los modelos de Machine Learning mostraron un mejor desempeño en términos de precisión predictiva. Algoritmos como Random Forest y XGBoost son capaces de modelar relaciones complejas entre variables sin necesidad de asumir estructuras

funcionales específicas.

Esta capacidad resulta particularmente útil en el análisis de activos digitales, donde los precios pueden verse influenciados por múltiples factores que interactúan de forma no lineal.

## 8.2. Desempeño del Modelo LSTM

El modelo basado en redes neuronales recurrentes del tipo LSTM mostró un comportamiento competitivo en la predicción de la serie temporal analizada. Este tipo de arquitectura está diseñado específicamente para modelar datos secuenciales y capturar dependencias temporales de largo plazo.

Las redes LSTM incorporan mecanismos de memoria que permiten conservar información relevante de observaciones pasadas, lo que puede resultar ventajoso en el análisis de mercados financieros donde los patrones históricos influyen en el comportamiento futuro de los precios.

No obstante, el rendimiento de los modelos de Deep Learning depende en gran medida de factores como la arquitectura de la red, la cantidad de datos disponibles y los parámetros utilizados durante el proceso de entrenamiento.

## 8.3. Impacto del Horizonte de Predicción

Uno de los aspectos más relevantes observados durante el análisis fue la influencia del horizonte temporal de predicción en el desempeño de los modelos.

En general, los modelos tienden a ofrecer mayor precisión en predicciones de corto plazo, mientras que el error de predicción aumenta a medida que se amplía el horizonte temporal.

Este comportamiento es consistente con la literatura sobre predicción de series temporales financieras, donde se reconoce que la incertidumbre inherente a los mercados aumenta significativamente en predicciones de largo plazo.

Por lo tanto, la selección del modelo más adecuado puede depender no solo del algoritmo utilizado, sino también del horizonte temporal de predicción que se desea analizar.



## 8.4. Implicaciones para el Análisis de Criptomonedas

Los resultados obtenidos en esta investigación tienen implicaciones relevantes para el análisis de mercados de criptomonedas. En particular, sugieren que la incorporación de técnicas de inteligencia artificial puede mejorar significativamente la capacidad de predicción en comparación con métodos econométricos tradicionales.

Esto resulta especialmente relevante en el contexto actual, donde el volumen de datos financieros disponibles ha crecido considerablemente y donde las técnicas de ciencia de datos permiten extraer patrones complejos a partir de grandes conjuntos de información.

Asimismo, los resultados indican que los modelos de Machine Learning pueden constituir herramientas útiles para el desarrollo de sistemas de trading algorítmico y estrategias de inversión basadas en datos.

## 8.5. Relación con Estudios Previos

Los hallazgos de este estudio son consistentes con investigaciones previas que han demostrado la eficacia de los algoritmos de Machine Learning en la predicción de series financieras.

Diversos estudios han encontrado que modelos como Random Forest y XGBoost pueden superar a modelos econométricos tradicionales en términos de precisión predictiva cuando se aplican a activos financieros altamente volátiles.

De igual manera, investigaciones recientes han destacado el potencial de las redes neuronales recurrentes para capturar dependencias temporales complejas presentes en datos financieros.

En este sentido, los resultados obtenidos en el presente trabajo contribuyen a reforzar la evidencia existente en la literatura sobre la utilidad de las técnicas de inteligencia artificial en el análisis de mercados financieros emergentes.

# Capítulo 9

## Conclusiones y Recomendaciones

### 9.1. Conclusiones

La presente investigación tuvo como objetivo principal comparar el desempeño predictivo de diferentes modelos utilizados en el análisis de series financieras de alta volatilidad, utilizando como caso de estudio el precio histórico de la criptomoneda Solana.

A partir de los resultados obtenidos, se pueden establecer diversas conclusiones relevantes.

En primer lugar, se observó que los modelos econométricos tradicionales, como ARIMA y GARCH, presentan limitaciones al aplicarse a mercados altamente volátiles como el de las criptomonedas. Si bien estos modelos permiten capturar patrones temporales y estimar la volatilidad de la serie financiera, su capacidad para modelar relaciones no lineales es relativamente limitada.

En segundo lugar, los modelos de Machine Learning mostraron un desempeño superior en términos de precisión predictiva. Algoritmos como Random Forest y XGBoost demostraron una mayor capacidad para capturar patrones complejos presentes en la serie temporal, lo que se tradujo en menores errores de predicción en comparación con los modelos econométricos tradicionales.

En tercer lugar, el modelo de Deep Learning basado en redes neuronales LSTM mostró resultados competitivos en la predicción del precio del activo, especialmente en horizontes temporales de mediano plazo. La capacidad de estas redes para modelar dependencias temporales de largo plazo constituye una ventaja importante en el análisis de series financieras.

Asimismo, se observó que el desempeño de los modelos depende significativamente del horizonte temporal de predicción considerado. En general, los modelos presentan mayor precisión en predicciones de corto plazo, mientras que la incertidumbre aumenta a medida que se amplía el horizonte temporal.

Adicionalmente, las simulaciones Monte Carlo permitieron generar escenarios probabilísticos sobre la evolución futura del precio del activo, proporcionando una perspectiva complementaria al análisis de predicción puntual realizado mediante los modelos.

En conjunto, los resultados obtenidos sugieren que la integración de técnicas de Machine Learning y Deep Learning puede contribuir significativamente a mejorar la precisión en la predicción de activos financieros altamente volátiles como las criptomonedas.

## 9.2. Aportes de la Investigación

El presente estudio aporta diversas contribuciones relevantes tanto desde una perspectiva académica como aplicada.

Desde el punto de vista académico, la investigación amplía la literatura existente sobre predicción de criptomonedas mediante un análisis comparativo entre modelos econométricos tradicionales, algoritmos de Machine Learning y arquitecturas de Deep Learning.

Desde una perspectiva metodológica, el estudio demuestra la utilidad de combinar diferentes enfoques analíticos para comprender mejor el comportamiento de los mercados financieros emergentes.

Asimismo, la investigación proporciona evidencia empírica sobre el desempeño relativo de distintos modelos predictivos aplicados al mercado de criptomonedas, lo cual puede resultar útil para investigadores interesados en el desarrollo de nuevas metodologías de análisis financiero.

## 9.3. Limitaciones del Estudio

A pesar de los resultados obtenidos, es importante reconocer ciertas limitaciones presentes en el estudio.

En primer lugar, el análisis se basa únicamente en una criptomoneda específica, lo que limita la generalización de los resultados a otros activos digitales.

En segundo lugar, el desempeño de los modelos de inteligencia artificial depende en gran medida de factores como la calidad de los datos disponibles, la selección de variables y la optimización de los parámetros del modelo.

Finalmente, el comportamiento de los mercados financieros puede verse influenciado por eventos externos difíciles de modelar, como cambios regulatorios, crisis económicas o eventos tecnológicos imprevistos.

## 9.4. Líneas Futuras de Investigación

A partir de los resultados obtenidos en este estudio, se pueden identificar diversas líneas de investigación futuras.

Una posible extensión consiste en aplicar los modelos analizados a otras criptomonedas con diferentes características de mercado, como Bitcoin o Ethereum.

Asimismo, futuras investigaciones podrían explorar el uso de modelos híbridos que combinen técnicas econométricas con algoritmos de aprendizaje automático.

Otra línea interesante de investigación consiste en incorporar variables adicionales en los modelos predictivos, tales como indicadores macroeconómicos, métricas de actividad en blockchain o indicadores de sentimiento provenientes de redes sociales.

Finalmente, el desarrollo de modelos de inteligencia artificial más avanzados, como arquitecturas basadas en Transformers o modelos de atención, podría ofrecer nuevas oportunidades para mejorar la precisión en la predicción de series financieras.

# Bibliografía

- [1] Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- [2] Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time Series Analysis: Forecasting and Control* (5th ed.). Wiley.
- [3] Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- [4] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794.
- [5] Engle, R. F. (1982). Autoregressive conditional heteroskedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.
- [6] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- [7] Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780.
- [8] Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: Principles and Practice*. OTexts.
- [9] McNally, S., Roche, J., & Caton, S. (2018). Predicting the price of Bitcoin using machine learning. *Proceedings of the 26th Euromicro International Conference on Parallel, Distributed and Network-Based Processing*, 339–343.
- [10] Nakamoto, S. (2008). *Bitcoin: A Peer-to-Peer Electronic Cash System*.

- [11] Sebastião, H., & Godinho, P. (2021). Forecasting and trading cryptocurrencies with machine learning under changing market conditions. *Expert Systems with Applications*, 180.
- [12] Tsay, R. S. (2010). *Analysis of Financial Time Series*. Wiley.
- [13] Livieris, I. E., Pintelas, E., & Pintelas, P. (2020). A CNN–LSTM model for gold price time-series forecasting. *Neural Computing and Applications*, 32, 17351–17360.